

Përmbledhje e analizës

Klasifikimi i Gjendjeve Shëndetësore nga të Dhënat e Mikrobiomës Përmes Analizës së Rrjetave Komplekse dhe Metodave të Machine Learning.

Qëllimi

Studimi zhvillon dhe vlerëson një qasje për klasifikimin e gjendjeve shëndetësore (healthy kundrejt diabetit të tipit 2, T2D) nga të dhënat e mikrobiomës së zorrës, duke integruar veçori topologjike dhe spektrale të rrjetave mikrobike me algoritme të Machine Learning. Punimi është një vlerësim bioinformatik dhe metodologjik, jo një model klinik diagnostikues.

Të dhënat

U përdor dataset-i QinJ_2012 (Qin et al., 2012, Nature), i marrë nëpërmjet paketës curatedMetagenomicData. Ai përmban 363 mostra (193 healthy dhe 170 T2D) me 651 veçori në nivel species. Matrica e abundancës ka rreth 86% vlera zero (sparsity i lartë).

Metodologjia

Të dhënat u ndanë në train dhe test (80/20 e stratifikuar) dhe u normalizuan. Mbi të dhënat e trajnimit u ndërtuan rrjeta mikrobike duke përdorur korrelacionin Spearman me një prag fiks 0.3 (që korrespondon afërsisht me percentilin 98.3 të shpërndarjes së korrelacioneve absolute). Nga rrjetat u nxorën veçori në nivel mostre, topologjike dhe spektrale, të ponderuara me abundancën. U testuan tre skenarë: S1 (vetëm abundanca), S2 (vetëm veçoritë e rrjetit) dhe S3 (kombinimi). Për secilin u trajnuan katër modele (Logistic Regression, SVM, Random Forest, XGBoost), të vlerësuar me 5-fold cross-validation (me mesatare dhe devijim standard të F1). Performanca u raportua për të dyja klasat (T2D dhe healthy) me Precision, Recall dhe F1, si dhe me Accuracy, Macro F1, Balanced Accuracy dhe ROC AUC, me fokus te klasa T2D.

Rezultatet kryesore

Performanca më e lartë u arrit në skenarin S1: XGBoost shënoi F1 0.711 për klasën healthy dhe rreth 0.69 për klasën T2D, me Balanced Accuracy rreth 0.70, ndërsa Random Forest arriti ROC AUC 0.790. Kombinimi në S3 dha përmirësim për disa modele dhe metrika (p.sh. F1 i Random Forest dhe i Logistic Regression), por jo në mënyrë të njëtrajtshme. Skenari S2, me veçori vetëm nga rrjeti, rezultoi më i dobët; kjo nuk përbën dështim, por tregon se veçoritë e rrjetit vetëm nuk mjaftojnë për klasifikim të fortë, ndërsa japin informacion plotësues kur kombinohen me abundancën. Te feature importance mbizotëruan veçoritë e abundancës, por pesë veçori të rrjetit u përfshinë midis njëzet më të rëndësishmeve.

Krahasimi strukturor i rrjetave

Rrjeti healthy doli më i lidhur se ai T2D: më shumë lidhje (4849 kundrejt 4335), degree mesatar, densitet, koeficient grumbullimi dhe lidhshmëri algjebrike më të larta. Modulariteti ishte më i lartë në rrjetin T2D. Këto dallime kanë vlerë interpretimi dhe lidhen me konceptin e disbiozës.

Hipotezat

H1 (kombinimi përmirëson klasifikimin) u mbështet pjesërisht; H2 (kontributi spektral) mori mbështetje të kufizuar; H3 (dallime strukturore midis grupeve) u mbështet; H4 (veçoritë e rrjetit konkurruese ose plotësuese) u mbështet pjesërisht, si plotësuese por jo zëvendësuese.

Përfundimet

Modelet me abundancë mbeten bazë e qëndrueshme; veçoritë e rrjetit vetëm nuk mjaftojnë gjithmonë; kombinimi jep informacion plotësues për disa modele; rrjetat healthy dhe T2D shfaqin dallime strukturore me vlerë interpretimi; integrimi i rrjetave me Machine Learning është qasje premtuese, por kërkon validim të mëtejshëm, sidomos në dataset-e të jashtme.